

UNIVERSIDADE ESTÁCIO DE SÁ

Relatório Técnico

Sistema de Detecção de Fraudes em Transações Financeiras utilizando Python
e Machine Learning

Eduardo Ferreira Rocha
Gustavo Bispo da Silva
Henrique Gomes da Silva

Carapicuíba — SP
2025

Eduardo Ferreira Rocha
Gustavo Bispo da Silva
Henrique Gomes da Silva

Relatório desenvolvido como requisito parcial para avaliação acadêmica, no curso da Universidade Estácio de Sá. O trabalho apresenta o desenvolvimento de um sistema computacional para detecção de fraudes utilizando técnicas de aprendizado de máquina.

Carapicuíba — SP
2025

SUMÁRIO

1. Introdução
2. Fundamentação Teórica
3. Geração do Dataset
4. Tratamento dos Dados
5. Engenharia de Atributos
6. Modelo de Machine Learning
7. Avaliação do Modelo
8. Funcionamento do Sistema
9. Limitações
10. Expansões Futuras
11. Conclusão
12. Referências

1. Introdução

A detecção de fraudes é uma área essencial no contexto tecnológico atual, especialmente em sistemas financeiros que envolvem grande volume de transações digitais. Este trabalho apresenta o desenvolvimento completo de um sistema capaz de estimar a probabilidade de fraude utilizando técnicas de machine learning e uma base de dados sintética construída especificamente para fins acadêmicos.

2. Fundamentação Teórica

Modelos de classificação binária são amplamente utilizados em sistemas antifraude. Dentre as técnicas empregadas, destacam-se regressão logística, árvores de decisão, métodos ensemble e aprendizagem online. O modelo utilizado neste projeto baseia-se em técnicas lineares otimizadas com gradiente descendente estocástico.

3. Geração do Dataset

O dataset foi gerado artificialmente com 50.000 transações, incluindo identificadores, valores, comerciantes, países, timestamps e indicação de fraude. O objetivo foi simular um ambiente próximo ao encontrado em empresas reais.

4. Tratamento dos Dados

Foram aplicadas técnicas de limpeza, padronização e conversão de variáveis categóricas. A ferramenta FeatureHasher foi utilizada para transformar textos em vetores numéricos.

5. Engenharia de Atributos

Foram selecionados atributos simples, mas eficazes: valor da transação, comerciante e país. Em sistemas reais, atributos adicionais como padrões temporais e comportamento do usuário poderiam ser aplicados.

6. Modelo de Machine Learning

O SGDClassifier com função log_loss foi utilizado, resultando em um modelo rápido e capaz de retornar probabilidades. O StandardScaler foi empregado para melhorar a convergência e a estabilidade numérica.

7. Avaliação do Modelo

A divisão treino/teste (80/20) permitiu análise adequada das métricas de desempenho. Apesar do desbalanceamento (3% fraudes), o modelo apresentou comportamento

satisfatório dentro da proposta educacional.

8. Funcionamento do Sistema

O sistema final possui interface interativa em que o usuário informa os dados da transação e recebe o cálculo da probabilidade de fraude. A resposta é categorizada entre risco baixo, médio ou alto.

9. Limitações

O conjunto de dados é sintético, o que reduz a aderência a padrões reais. Modelos lineares também possuem limitação ao capturar relações não lineares complexas.

10. Expansões Futuras

Sugere-se a adoção de modelos mais robustos como XGBoost ou redes neurais, integração com APIs, dashboard de monitoramento e análise comportamental mais avançada.

11. Conclusão

O trabalho demonstra todas as etapas necessárias para a construção de um sistema antifraude, desde a concepção da base de dados até a implementação final do modelo preditivo.

12. Referências

Documentações oficiais do scikit-learn, pandas, NumPy, além de artigos acadêmicos sobre detecção de anomalias e classificação binária.